文档智能入库助手 — 产品需求文档（PRD

产品负责人：代明昊（Jasper）

版本：V1.0 Release

日期：2026.03.15

技术栈：Python + Streamlit + 智谱GLM API

开发方式：Claude Code（Vibe Coding，零手写代码）

GitHub：https://github.com/Ddddd917/doc-ingestion-tool

一、产品定义

1.1 一句话描述

一个基于智谱GLM大模型的个人知识库文档入库工具，自动提取摘要、分类知识域、生成结构化标签，支持本地文件管理与AI驱动的知识洞察。

1.2 解决的核心痛点

痛点	当前做法	本工具解决方式
文档散乱无分类	手动创建文件夹，凭记忆归类	AI自动识别文档主题，归类到8大知识域，文件自动移动到对应文件夹
找不到"之前看过的东西"	翻文件夹、搜关键词碰运气	自动生成摘要和标签，结构化元数据支持快速检索
知识库建设启动成本高	想做但没开始，整理太耗时	拖入文档 → 一键分析 → 确认入库 → 自动归档
不知道自己的知识盲区在哪	靠感觉判断	AI洞察自动分析知识库覆盖度，指出盲区和改进方向
文件命名不规范	随手命名，格式混乱	AI生成标准化命名建议：日期_知识域_主题_文档类型

1.3 产品定位

个人「第二大脑」系统的**数据入库前端工具 + 知识管理仪表盘**。它解决的是"非结构化文档如何高效进入知识库并保持可管理"的问题。

1.4 目标用户

- 知识工作者（产品经理、研究员、学生）
- 有大量散乱文档需要整理归类的个人用户
- 正在构建个人知识体系的学习者

二、系统架构

2.1 技术架构

```
┌──────────────────────────────────────────────────────────┐
│              Streamlit 多页应用（9个页面）                  │
│   ┌──────────┬──────────┬──────────────────┐              │
│   │ Dashboard │ 上传分析   │ 8个知识域页面     │ │
│   │ （首页）   │ （入库操作）│ （浏览/管理）     │ │
│   └──────────┴──────────┴──────────────────┘              │
├──────────────────────────────────────────────────────────┤
│                 业务逻辑层（core/）                          │
│   ┌─────────┬─────────┬─────────┬──────────────┐          │
│   │文档解析 │AI分析   │文件管理 │ 元数据存储    │ │
│   │parser   │analyzer│manager │ metadata     │ │
│   ├─────────┼─────────┼─────────┼──────────────┤          │
│   │知识域   │导出引擎 │Memory  │ 通用域页面    │ │
│   │config   │exporter│manager │ domain_page  │ │
│   └─────────┴─────────┴─────────┴──────────────┘          │
├──────────────────────────────────────────────────────────┤
│                 外部服务                                    |
│   ┌──────────────────────────────────────────┐             |
│   │ 智谱 GLM-4-FlashX API                      ||
│   │ （摘要生成、分类、标签提取、AI洞察）          ||
│   └──────────────────────────────────────────┘             |
├──────────────────────────────────────────────────────────┤
│                 本地存储                                    |
│  ~/Documents/SecondBrain/                                  |
│   ├── metadata.json   （全部文档元数据）                    |
│   ├── memory.json     （AI洞察持久化）                      |
│   ├── 01_学术知识/                                          |
│   ├── 02_职业经验/                                          |
```

```
│   ├── 03_AI与技术/                                  │
│   ├── 04_阅读笔记/                                  │
│   ├── 05_目标与计划/                                │
│   ├── 06_思考与洞察/                                │
│   ├── 07_生活记录/                                  │
│   └── 08_影视与文化/                                │
└──────────────────────────────────────────────────┘
```

2.2 项目文件结构

```
doc-ingestion-tool/
├── app.py                      # 主入口：st.navigation 多页
导航 + 侧边栏
├── pages/
│   ├── dashboard.py            # 📊 Dashboard（默认首页）
│   ├── upload.py               # 📤 上传与分析（含入库操作）
│   ├── academic.py             # 🎓 学术知识
│   ├── career.py               # 💼 职业经验
│   ├── ai_tech.py              # 🤖 AI与技术
│   ├── reading.py              # 📖 阅读笔记
│   ├── goals.py                # 🎯 目标与计划
│   ├── insights.py             # 💭 思考与洞察
│   ├── life.py                 # 🍳 生活记录
│   └── culture.py              # 🎬 影视与文化
├── core/
│   ├── __init__.py
│   ├── config.py               # 知识库路径、域名映射、颜色配
置、目录初始化
│   ├── llm_client.py           # 智谱GLM API封装
│   ├── doc_parser.py           # 文档解析（PDF/MD/TXT）
│   ├── doc_analyzer.py         # AI分析引擎（摘要+分类+标签）
│   ├── file_manager.py         # 文件命名建议 + 移动重命名
│   ├── metadata_store.py       # metadata.json 增删改查
│   ├── memory_manager.py       # AI洞察生成 + memory.json
持久化
│   ├── domain_page.py          # 8个知识域页面的通用渲染函数
│   └── exporter.py             # 导出引擎（JSON/CSV/Markdow
n）
```

```
├── data/
├── exports/
├── requirements.txt
├── .env
├── .env.example
├── .gitignore
├── README.md
└── PRD_文档智能入库助手.md       # 本文档
```

三、功能模块详述

3.1 页面1：📊 Dashboard

定位：应用首页，提供知识库全局视图和AI驱动的个人洞察。

板块1：核心指标

- 4个 st.metric 并排：总文档数、去重标签数、已覆盖知识域数(/8)、最近入库距今天数

板块2：知识域分布

- 左列：柱状图展示8个知识域的文档数量（含0值域）
- 右列：明细列表，按数量降序，显示域名+文档数+占比百分比

板块3：入库时间线

- 最近30天的每日入库文档数（面积图）
- 底部统计：最近7天/30天入库篇数

板块4：高频标签云

- Top 20高频标签
- 字号14-36px线性映射频率
- 颜色取标签所在主知识域的配色

板块5：最近入库文档

- 最新5篇文档：文件名 + 知识域彩色标签 + 相对时间

板块6：📡 AI洞察

- 「🔄 刷新洞察」按钮，触发LLM调用，分析全部已入库文档的元数据
- 洞察内容从 memory.json 读取，包含：
  - 📝 最近在忙什么（100字总结）
  - 🎯 近期重心（3-5个标签）
  - ✅ 做得好的（3-5条具体反馈）
  - ⚠️ 需要改进的（3-5条可执行建议）
  - 🕳️ 知识盲区（2-3个待补充方向）
- 入库新文档后自动更新洞察

空状态处理

- 无文档时显示引导：「🚀 开始构建你的第二大脑 — 去上传与分析页面添加你的第一个文档」

3.2 页面2：📤 上传与分析

定位：文档入库的核心操作页面。

区域1：文档上传

- st.file_uploader 支持多文件上传
- 支持格式：PDF、Markdown（.md）、TXT
- 上传后显示文件列表（文件名 + 大小 + 格式图标）
- 「🚀 开始处理」按钮

区域2：处理过程

- 逐个文件调用 doc_parser → doc_analyzer
- st.status 显示当前处理文件
- st.progress 显示整体进度
- 结果存入 st.session_state

区域3：分析结果展示

每个文档一个 st.expander 卡片，内含：

模块	组件	可编辑
📝 摘要	st.text_area	✅
🎯 关键要点	st.markdown 列表	❌
📚 知识域	彩色HTML标签 + 置信度百分比	❌
🏷️ 标签	st.text_input（逗号分隔）	✅
📊 文档信息	4列metric：类型/语言/难度/字数	❌

区域4：入库操作

每个文档卡片底部：

- 「建议文件名」：st.text_input，预填AI建议的标准化命名，可修改
- 「目标知识域」：st.selectbox，预选AI判断的主知识域，可修改
- 「✅ 确认入库」按钮：执行文件重命名 → 移动到对应知识域文件夹 → 保存元数据 → 触发洞察更新

区域5：导出

- 统计信息：共处理X个文档 | 覆盖Y个知识域 | 生成Z个标签
- 三个下载按钮：导出JSON / 导出CSV / 导出Markdown

3.3 页面3-10：8个知识域页面

定位：按知识域浏览和管理已入库文档。

8个页面使用通用渲染函数 `core/domain_page.py`，结构完全一致：

知识域	Emoji	文件夹	颜色
学术知识	🎓	01_学术知识	#4A90D9
职业经验	💼	02_职业经验	#50C878
AI与技术	🤖	03_AI与技术	#9B59B6
阅读笔记	📖	04_阅读笔记	#E67E22
目标与计划	🎯	05_目标与计划	#E74C3C
思考与洞察	💭	06_思考与洞察	#1ABC9C
生活记录	🍳	07_生活记录	#FF69B4
影视与文化	🎬	08_影视与文化	#F1C40F

页面功能

文档筛选：

- toggle「显示关联文档」（默认关闭）
- 关闭：只显示主知识域匹配的文档
- 开启：同时显示关联文档，用 📌/🔗 图标和分组标题区分

文档卡片（st.expander，按入库时间倒序）：

- 📝 摘要（只读）
- 🎯 关键要点（列表）
- 🏷️ 标签（彩色HTML标签）
- 📊 文档信息（类型/语言/难度/字数）
- 📂 文件位置 + 「在Finder中打开」按钮

⚙️ **文件管理**（嵌套expander，默认收起）：

操作	触发方式	执行逻辑
✏️ 重命名	text_input + 确认按钮	os.rename → 更新metadata
📦 移动知识域	selectbox + 确认按钮	shutil.move → 更新metadata路径和域
🗑️ 删除	checkbox安全开关 + 确认按钮	os.remove → 删除metadata记录

标签云：页面底部，统计该域下所有文档标签频率Top 10。

四、核心逻辑详述

4.1 AI分析引擎（doc_analyzer.py）

- 输入：doc_parser 解析的文档数据（文件名、内容、格式、字数）
- 内容超过8000字时截取前8000字
- 调用智谱GLM-4-FlashX，System Prompt要求返回JSON
- 输出结构：summary, key_points, domains（含置信度和分类理由）, tags, document_type, language, difficulty_level
- JSON解析兼容markdown代码块包裹，失败时返回默认结构

8大知识域分类规则：

1. 学术知识 — CS课程、算法、编程、学术项目
2. 职业经验 — 实习、工作、行业洞察、职业发展

3. AI与技术 — AI工具、大模型、技术趋势、产品技术
4. 阅读笔记 — 书籍、文章、论文的阅读记录
5. 目标与计划 — 求职、学习计划、个人规划
6. 思考与洞察 — 行业思考、产品灵感、复盘反思
7. 生活记录 — 食谱、健身、理财、旅行、日常
8. 影视与文化 — 电影、音乐、文化相关内容

4.2 文件命名规则（file_manager.py）

命名格式： `{YYYYMMDD}_{知识域缩写}_{主题}_{文档类型}.{原扩展名}`

知识域缩写映射：

知识域	缩写
学术知识	学术
职业经验	职业
AI与技术	AI
阅读笔记	阅读
目标与计划	目标
思考与洞察	思考
生活记录	生活
影视与文化	影视

文档类型提取逻辑：

1. 优先从tags中提取特殊关键词（面试复盘、面试准备、竞品分析、调研报告等）
2. 未匹配时从document_type字段映射（笔记/报告/论文/文章/手册/其他→文档）

命名示例：

- `20260315_职业_商汤科技_AI产品经理_面试复盘.pdf`
- `20260315_AI_AI工具_全景地图_笔记.pdf`
- `20260315_AI_ChatGPT_Claude_竞品分析.md`

4.3 元数据存储（metadata_store.py）

存储路径：`~/Documents/SecondBrain/metadata.json`

每条记录结构：

```
{
  "file_name": "20260315_职业_商汤科技_AI产品经理_面试复盘.pdf",
  "original_name": "商汤科技面试复盘.pdf",
  "summary": "商汤科技AI产品经理实习生面试复盘...",
  "key_points": ["面试问题分类及评分", "..."],
  "domains": [
    {"name": "职业经验", "confidence": 0.95, "reason":
"..."},
    {"name": "AI与技术", "confidence": 0.85, "reason":
"..."}
  ],
  "tags": ["商汤科技", "AI产品经理", "面试复盘", "..."],
  "document_type": "笔记",
  "language": "中文",
  "difficulty_level": "中级",
  "word_count": 5928,
  "processed_at": "2026-03-15T16:12:00",
  "file_path": "/Users/jasper/Documents/SecondBrain/02_职业
经验/20260315_职业_商汤科技_AI产品经理_面试复盘.pdf"
}
```

支持的操作：load / save / add_record / get_records_by_domain / get_records_by_primary_domain / get_records_by_related_domain / update_record / delete_record

4.4 AI洞察与Memory（memory_manager.py）

存储路径：`~/Documents/SecondBrain/memory.json`

Memory结构：

```
{
  "last_updated": "2026-03-15T16:30:00",
  "weekly_summary": "本周主要关注职业发展...",
  "recent_focus": ["腾讯云面试复盘", "智谱面试复盘", "..."],
  "strengths": ["能够对面试过程进行详细复盘", "..."],
  "improvements": ["需要加强时间管理", "..."],
  "knowledge_gaps": ["学术知识领域需要补充", "..."]
}
```

更新触发机制：

- 手动触发：Dashboard页面「🔄 刷新洞察」按钮
- 自动触发：入库新文档后，如果已有洞察数据则自动更新

生成逻辑：

- 收集全部已入库文档的元数据（摘要+标签+关键要点）
- 控制上下文在6000字以内（超出取最近20篇）
- 调用LLM生成结构化洞察JSON
- 持久化到memory.json

五、技术依赖

5.1 requirements.txt

```
streamlit
zhipuai
pypdf
python-dotenv
pandas
plotly
```

5.2 外部服务

服务	用途	模型
智谱GLM API	文档分析、AI洞察生成	glm-4-flashx

5.3 运行环境

- Python 3.8+
- macOS（文件管理功能使用 `open -R` 命令）
- 本地运行，无需部署服务器

六、数据流

6.1 文档入库流程

```
用户上传文档
    ↓
doc_parser.parse_file()  →  提取文本内容
    ↓
doc_analyzer.analyze_document()  →  调用LLM生成摘要/分类/标签
    ↓
file_manager.suggest_filename()  →  生成标准化文件名建议
    ↓
用户确认/修改文件名和目标知识域
    ↓
file_manager.move_and_rename()  →  文件移动到知识域文件夹
    ↓
metadata_store.add_record()  →  元数据写入metadata.json
    ↓
memory_manager.generate_insights()  →  更新AI洞察（如已有洞察）
```

6.2 文件管理流程

```
用户在知识域页面展开文件管理
    ↓
重命名：os.rename → update_record
移动：shutil.move → update_record（路径+域）
删除：os.remove → delete_record
    ↓
st.rerun() 刷新页面
```

七、设计规范

7.1 知识域配色

知识域	颜色代码	色彩
学术知识	#4A90D9	蓝色
职业经验	#50C878	绿色
AI与技术	#9B59B6	紫色
阅读笔记	#E67E22	橙色

知识域	颜色代码	色彩
目标与计划	#E74C3C	红色
思考与洞察	#1ABC9C	青色
生活记录	#FF69B4	粉色
影视与文化	#F1C40F	黄色

7.2 侧边栏布局

```
📊 Dashboard          ← 默认首页
📤 上传与分析
──────────────
🎓 学术知识
💼 职业经验
🤖 AI与技术
📖 阅读笔记
🎯 目标与计划
💭 思考与洞察
🍳 生活记录
🎬 影视与文化
──────────────
📚 第二大脑
已入库 X 篇文档
```

八、开发历程

本项目全程使用 Claude Code 以 Vibe Coding 方式开发，零手写代码。

阶段	Prompt	内容	耗时（估算）
P1	Prompt 1	项目初始化：目录结构、依赖安装、API封装、文档解析	15min
P2	Prompt 2	AI分析引擎 + 完整单页应用	30min
P3A	Prompt 3A	多页架构重构 + 本地文件管理基础设施	30min
P3B	Prompt 3B	8个知识域页面内容实现	20min
P3C	命名修复	文件命名规则优化（增加文档类型维度）	10min

阶段	Prompt	内容	耗时（估算）
P3D	文件管理	知识域页面增加重命名/移动/删除功能	15min
P3E	关联文档	主知识域/关联知识域显示逻辑优化	10min
P4A	Prompt 4A	Dashboard数据统计板块（6个板块）	20min
P4B	Prompt 4B	AI洞察 + Memory持久化	25min
收尾	清理	删除面试追踪功能、生成PRD	10min

总开发时间：约 3 小时（含测试和迭代）

九、简历表述与面试话术

简历写法

文档智能入库助手 ｜ Python, Streamlit, GLM API, Claude Code

- 使用Claude Code零手写代码开发个人知识管理工具：上传PDF/Markdown/TXT文档后AI自动生成摘要、知识域分类（8大领域）及结构化标签，支持批量处理、手动校正与本地文件自动归档
- 构建AI驱动的Dashboard，基于知识库元数据自动生成个人洞察（近期重心、优势、改进建议、知识盲区），持久化存储支持增量更新
- 结果可一键导出为JSON/CSV/Markdown，为个人「第二大脑」提供标准化入库与管理流程

面试话术

「我在搭建个人第二大脑时发现文档入库是最大的摩擦点——手动整理分类太耗时。所以我用Claude Code做了这个工具：拖入文档，AI自动提取摘要、判断知识域、生成标签和标准化文件名，一键入库到本地文件夹。还做了一个Dashboard，基于全部文档元数据用LLM生成个人洞察——最近在忙什么、做得好的和需要改进的。这个项目让我对知识库产品的核心链路有切身体会——本质上企业知识库和个人知识库面临同一个问题：如何让非结构化文档变得可检索、可管理、可洞察。」

十、未来迭代方向

优先级	功能	说明
P1	导出功能完善	完善JSON/CSV/Markdown导出，支持读取用户编辑后

优先级	功能	说明
		的数据
P1	全局搜索	跨知识域搜索文档（按标签、关键词、摘要内容）
P2	向量数据库集成	接入ChromaDB，支持语义检索
P2	更多文件格式	支持DOCX、XLSX、图片OCR
P2	批量入库	选择本地文件夹，批量扫描并入库
P3	知识图谱可视化	标签间的关联关系图谱
P3	多设备同步	接入云存储（iCloud/飞书云文档）